

RELATÓRIO EXECUTIVO

Previsão de atraso de entrega no e-commerce brasileiro

Do dado público da Olist a um sistema de alertas proativos,
com avaliação honesta e cenário operacional em contagens

Thiago Ferreira · Julho de 2026

Código, notebooks e aplicativo interativo: github.com/tf-ferreira/olist-delivery-delay-prediction

1. Sumário executivo

O problema: 6,8% dos pedidos entregues do e-commerce brasileiro (dataset público Olist, 96.470 pedidos de 2016–2018) chegam depois da data prometida ao cliente. A empresa só descobre cada atraso quando ele já aconteceu, e reage apagando incêndio: reclamações, avaliações negativas e perda de recompra.

A solução construída: um modelo que estima, no instante em que a compra é concluída, a probabilidade de o pedido atrasar, usando apenas informações que existem naquele momento (endereço, promessa de prazo, atributos do produto e o histórico do vendedor até ali). A probabilidade alimenta uma política simples de operação: *notificar proativamente os k% pedidos de maior risco do mês*, com k escolhido pelo negócio.

2,2x

precisão dos alertas
vs escolha aleatória
(ponto default)

36%

dos atrasos
capturados
notificando 16% dos
pedidos

1.054

clientes notificados
por mês típico (~6,5
mil pedidos)

0,61–0,79

AUC-ROC mensal no
teste, estável através
de 3 regimes

Como foi avaliado: com a disciplina que produção exige. Divisão treino/teste no tempo (nunca aleatória), auditoria coluna a coluna contra vazamento de informação do futuro, e um conjunto de teste de seis meses aberto uma única vez. Os números acima são estimativas honestas de comportamento futuro, não métricas de laboratório.

A recomendação: piloto operacional de notificação proativa no ponto default (16% de orçamento de alertas), com monitoramento mensal da qualidade de ordenação e gatilho de retreino, e a evolução do modelo pela agenda de próximos passos da seção 8.

2. O problema e o valor

O atraso de entrega é a pior experiência do funil logístico, e é assimétrico: custa caro em reputação e recompra, mas a maioria esmagadora dos pedidos (93,2%) chega no prazo. Agir sobre todos os pedidos é caro demais; não agir sobre nenhum é o status quo reativo. O valor de um modelo de risco está exatamente no meio: **concentrar a atenção operacional nos pedidos certos, antes do estouro do prazo**. As ações possíveis com um score de risco no momento da compra: aviso proativo ao cliente (a expectativa gerenciada dói menos que a surpresa), priorização no fluxo de despacho, e cobrança dirigida aos vendedores de risco.

3. Os dados e o rigor de preparação

Base pública da Olist (marketplace brasileiro): 9 tabelas relacionais, ~100 mil pedidos reais de 2016 a 2018, com pedidos, itens, pagamentos, clientes, vendedores e geolocalização. A população analisada são os

96.470 pedidos entregues com data registrada; o alvo compara datas (a promessa é registrada à meia-noite, e a comparação ingênua por horário rotularia errado 1.292 pedidos entregues no próprio dia prometido).

A regra que governa o projeto: só entra no modelo o que era conhecido no instante da compra. Datas de aprovação, postagem e entrega, e as avaliações dos clientes, são posteriores e ficam banidas (auditoria coluna a coluna no repositório). A variável mais sensível, o histórico de cada vendedor, foi construída com relógios de disponibilidade: o desfecho de um pedido só entra no histórico quando aquele pedido é entregue, exatamente como uma feature store de produção veria. O contrato é verificado por testes automatizados e por um teste de sanidade: treinando com o alvo embaralhado, o desempenho desaba para o equivalente à moeda ao ar (0,500), como deve ser.

O pipeline de consolidação (9 tabelas → 1 linha por pedido) audita a contagem de linhas a cada junção e mantém valores faltantes sinalizados em vez de imputados, com as estatísticas de preenchimento aprendidas apenas no período de treino.

4. O que os dados revelam




Figura 1 · A taxa de atraso mensal varia de ~3% a 19%: Black Friday (nov/17), a crise logística de fev–mar/18 (o maior choque da série) e a recalibração de promessas pós-greva (jun/18, 1,2%).

1. **O atraso não é estável no tempo** (3% a 19% ao mês), o que exige avaliação temporal e monitoramento contínuo em produção.
2. **Geografia domina:** a taxa vai de 4,5% (SP) a 21,4% (AL); a distância vendedor→cliente tem gradiente limpo (4,6% → 9,7% por quintil). O caso de negócio mais forte: o Rio de Janeiro, segundo maior mercado (12.350 pedidos), atrasa quase 3x mais que SP.
3. **O atraso é relativo à promessa:** promessas intermediárias (17–22 dias) atrasam mais que as curtas e as longas, e pedidos multi-vendedor atrasam MENOS (a promessa igual com entrega real mais rápida gera

folga maior). A qualidade da calibração da promessa é parte do fenômeno.

4. **O risco de vendedor é concentrado e antecipável:** a segmentação identificou 128 vendedores (10% da base ativa) com taxa de atraso de 16,5% (2,4x a média) e despacho ~3x mais lento; a lentidão de postagem é sintoma visível antes do atraso.




Figura 2 · As três personas de vendedores (K-Means): os "gargalos logísticos" concentram o risco e são identificáveis pelo tempo de postagem.

5. O modelo e a avaliação honesta

Três modelos foram comparados em escada de complexidade (Regressão Logística, Random Forest, LightGBM), sob um protocolo fixado antes de qualquer treino: seleção de hiperparâmetros e do campeão num bloco de validação temporal dentro do treino, e um teste de seis meses (mar-ago/2018) consultado **uma única vez**, ao final. A campeã selecionada foi a **Regressão Logística regularizada**: sob a mudança de regime entre treino e validação, o modelo simples generalizou melhor que os de maior capacidade, um resultado que um split aleatório (a prática comum) teria escondido.

Modelo	AUC-PR no teste	vs acaso (7,0%)	AUC-ROC no teste
Regressão Logística (campeã)	0,138	2,0x	0,699
LightGBM	0,181	2,6x	0,742
Random Forest	0,137	2,0x	0,664

Transparência que importa: o LightGBM superou a campeã na passada única do teste. A troca não foi feita, porque trocar de modelo depois de ver o teste é usar o teste para selecionar, e a métrica resultante nasceria inflada. O aprendizado está registrado como evolução: seleção com validação em múltiplas janelas temporais antes de produção. Preferimos uma estimativa honesta com a incerteza documentada a uma métrica maior obtida quebrando o protocolo.

O que o modelo usa, em ordem de importância: UF de destino, janela prometida (prazos longos protegem), distância vendedor→cliente e o tempo de despacho histórico do vendedor. Tudo interpretável e alinhado aos achados da análise exploratória.

6. O cenário operacional, em contagens

A decisão de operação não é um número estatístico, é um orçamento: *quantos clientes notificar por mês*. Cada orçamento corresponde a um ponto da curva de troca entre capturar atrasos e gerar alarmes falsos. Três pontos de referência, medidos no teste (mês típico de ~6,5 mil pedidos):

Política	Notificados/mês	Atrasos capturados/mês	Falsos alarmes/mês	Precisão (vs 7% do acaso)
Conservadora (6%)	409	74 (16% dos atrasos)	335	18,1% (2,6x)
Default (16%)	1.054	166 (36%)	888	15,7% (2,2x)
Agressiva (42%)	2.728	313 (68%)	2.414	11,5% (1,6x)




Figura 3 - A curva de troca completa (validação) com os três pontos nomeados. O aplicativo interativo do projeto recalcula as contagens ao vivo para qualquer orçamento.

Nenhum valor monetário foi assumido neste relatório de propósito: contagens são indiscutíveis, e a conversão em dinheiro depende de dois números que pertencem ao negócio (custo de um contato proativo e custo evitado de um cliente surpreendido). Com esses dois números, a tabela acima vira uma conta de retorno imediata.

7. Robustez através dos regimes (e o argumento de monitoramento)




Figura 4 - Qualidade de ordenação mês a mês no teste: estável através da saída da crise, da greve dos caminhoneiros e da recalibração de promessas; o pior mês é o mais distante do treino.

O período de teste contém, deliberadamente, três regimes distintos: a saída da crise logística (março), a greve dos caminhoneiros (maio) e a recalibração de promessas (junho em diante). A capacidade de ordenação do modelo permaneceu acima do acaso em todos (AUC-ROC de 0,61 a 0,79). O padrão do pior mês, agosto, o mais distante do treino, é a assinatura clássica de envelhecimento de modelo, e fundamenta as duas práticas recomendadas para produção: **monitoramento mensal da métrica e gatilho de retreino**.

8. Limitações e próximos passos

Limitações, ditas com franqueza

- **Grão do pedido vs remessa:** pedidos com mais de um vendedor (1,3% da base) são agregados no nível do pedido; peso e volume somados não correspondem a uma remessa física única. Redesenho por grão de remessa especificado para iteração futura.
- **Seleção em janela única de validação:** como demonstrado pelo LightGBM no teste, a escolha do campeão tem variância; produção pede validação em múltiplas janelas.
- **Probabilidades não calibradas finamente:** a política por orçamento de alertas contorna isso por construção; calibração formal é evolução natural.
- **Escopo:** o modelo prevê atraso de pedidos entregues; cancelamentos e extravios são um problema distinto, fora deste ciclo. Pedidos sem cobertura de geolocalização (0,5%) usam sinalização explícita.

Próximos passos

1. **Piloto operacional** no ponto default, com métricas de aceite do cliente à notificação.
2. **Seleção robusta:** validação de origem rolante; reavaliar LightGBM como campeão; calibração de probabilidades.
3. **Novas fontes de sinal:** grão de remessa (padrão gargalo), risco por rota (origem × destino), capacidade da transportadora.
4. **Industrialização:** o desenho de produção descrito no repositório: ingestão orquestrada (Airflow), transformação com testes de qualidade de dados (dbt), treino e serving gerenciados (Databricks/Azure ML), feature store com os mesmos relógios de disponibilidade usados aqui, e monitoramento de drift com gatilho de retreino.

Reprodutibilidade: todo o caminho, dos dados brutos a este relatório, é reproduzível a partir do repositório público (notebooks narrados, pipeline auditado, testes automatizados e ambiente com versões fixadas). O aplicativo interativo permite explorar o cenário operacional com qualquer orçamento de alertas.